



AI • ANALYTICS **SUMMIT**

Online / **DIIC**
Perú





Workshop: Agilizando la Gestión de Modelos con MLOps

Ponente: Luis Cajachahua

Cargo y Empresa: Principal Data Scientist – Teradata

<https://www.linkedin.com/in/lcajachahua/>



Agenda

- Antecedentes
- MLOps
- Beneficios de MLOps
- Componentes Tecnológicos
- Soluciones Disponibles
- Demo AnalyticOps
- Mensajes Finales



Antecedentes



<https://github.com/lcajachahua/dataops-why-now>

RESULTADO

POCOS ÉXITOS MUCHOS FRACASOS

Informes de Analistas


- ❖ 85% of big data projects fail ([Gartner](#), 2017)
- ❖ 87% of data science projects never make it to production ([VentureBeat](#), 2019)
- ❖ "Through 2022, only 20% of analytic insights will deliver business outcomes" ([Gartner](#), 2019)





Tiempo de desarrollo de un modelo

- Considerando desde idea o necesidad hasta implementación y accionamiento.



The Great Attrition

Or the Great Attraction? A record number of employees are quitting their jobs, as the pandemic has irrevocably changed what workers expect. Organizations that learn why and act thoughtfully will have an edge in attracting and retaining talent

40%

of employees say they are likely to leave in the next 3-6 months

64%

of employees considering leaving say they would do so without another job in hand

38%

of employers believe attrition is due to compensation

But 52%

of employees leave because they don't feel valued by their managers

While 51%

of employees leave because they don't feel a sense of belonging at work



Employers do not fully understand why employees are leaving.

Factors that are important to employees versus what employers think is important


Employee views

Employer views

► Instead, employers overindex on transactional factors, which are not primary drivers. These include external factors (such as workers job-hunting) and structural aspects (compensation, for example).

Less important to employees than employers think

As important to employees as employers think

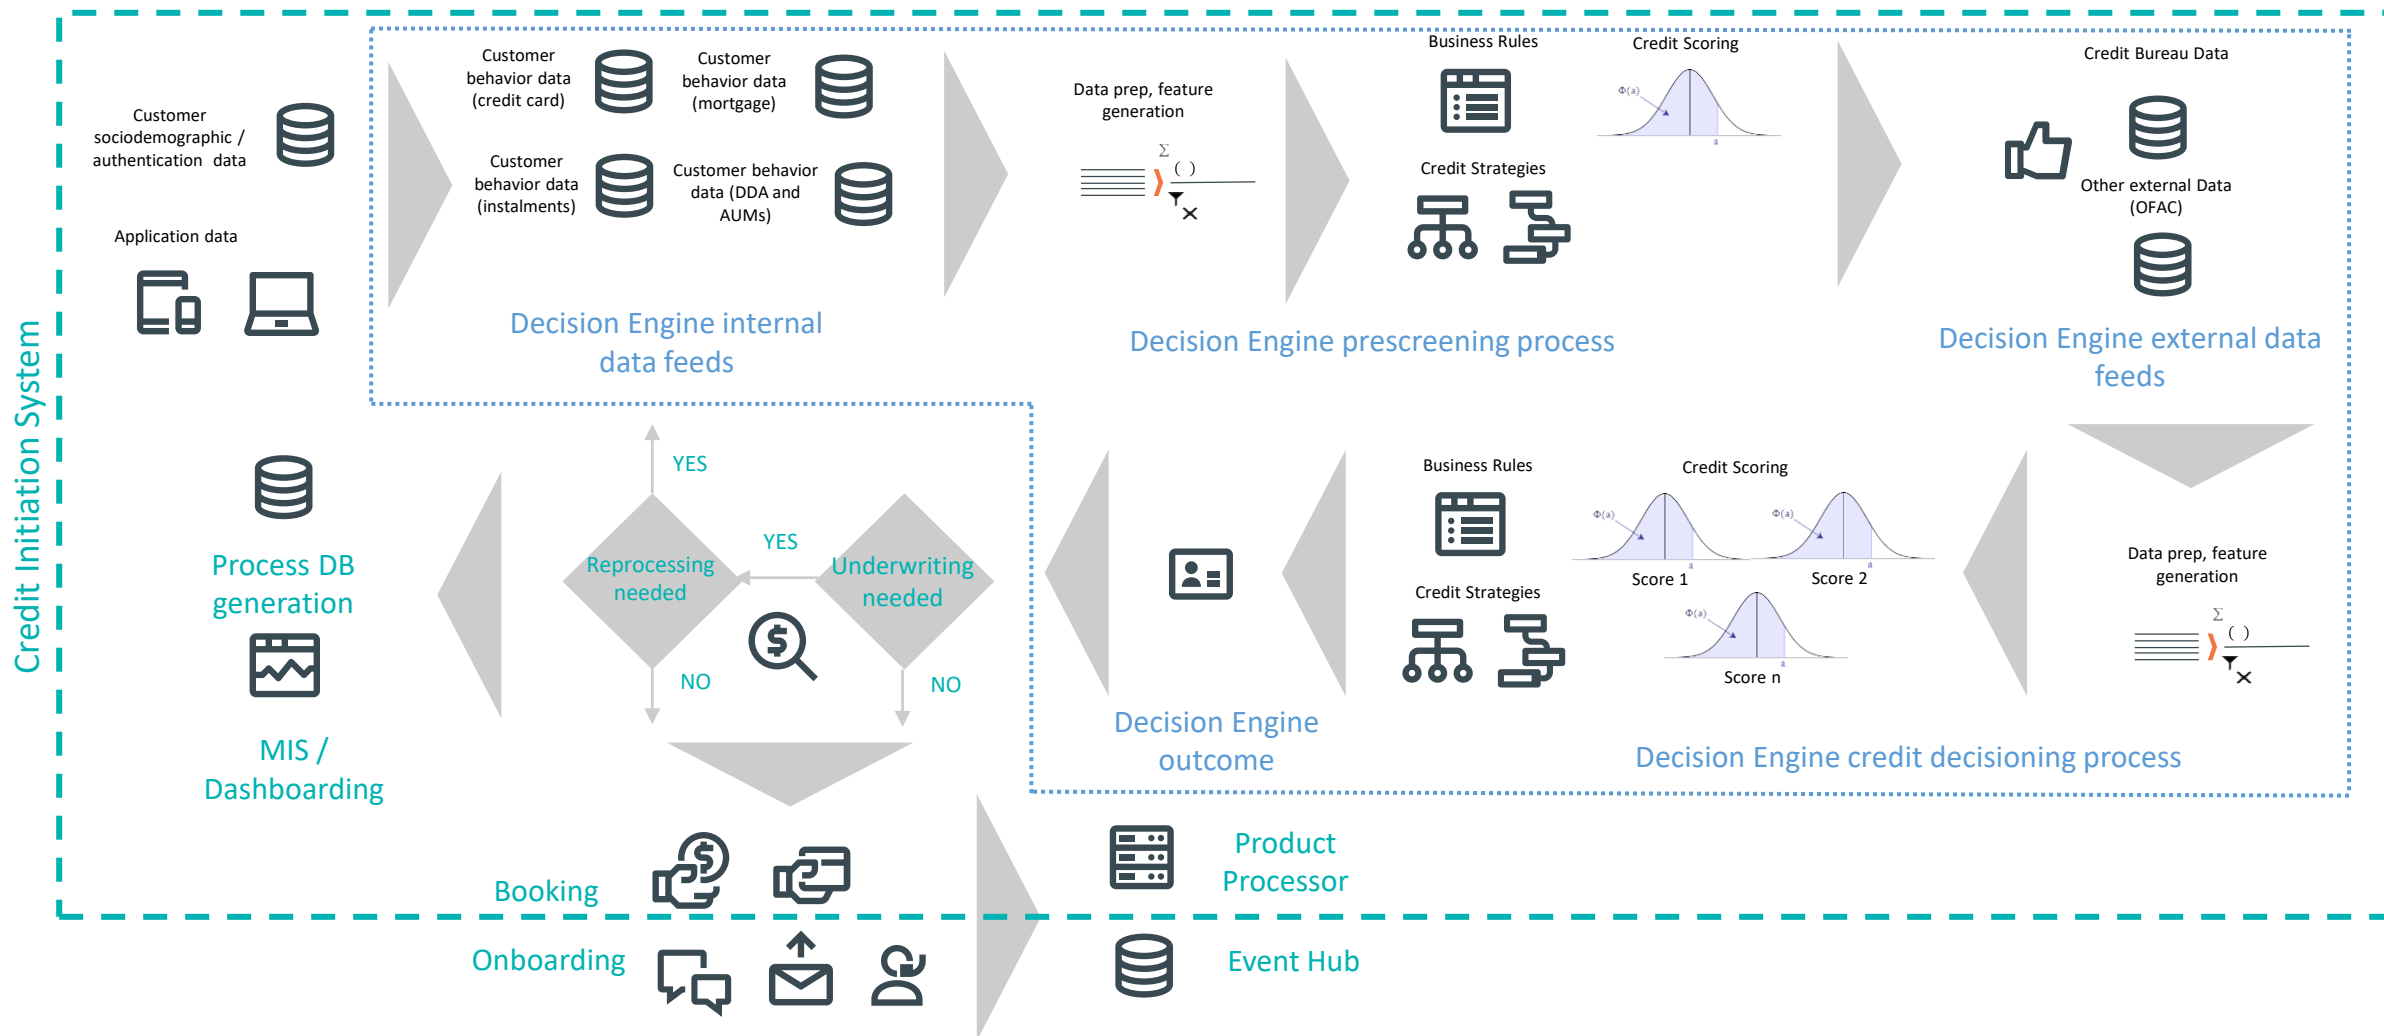


Panorama actual

De los equipos analíticos en Latinoamérica

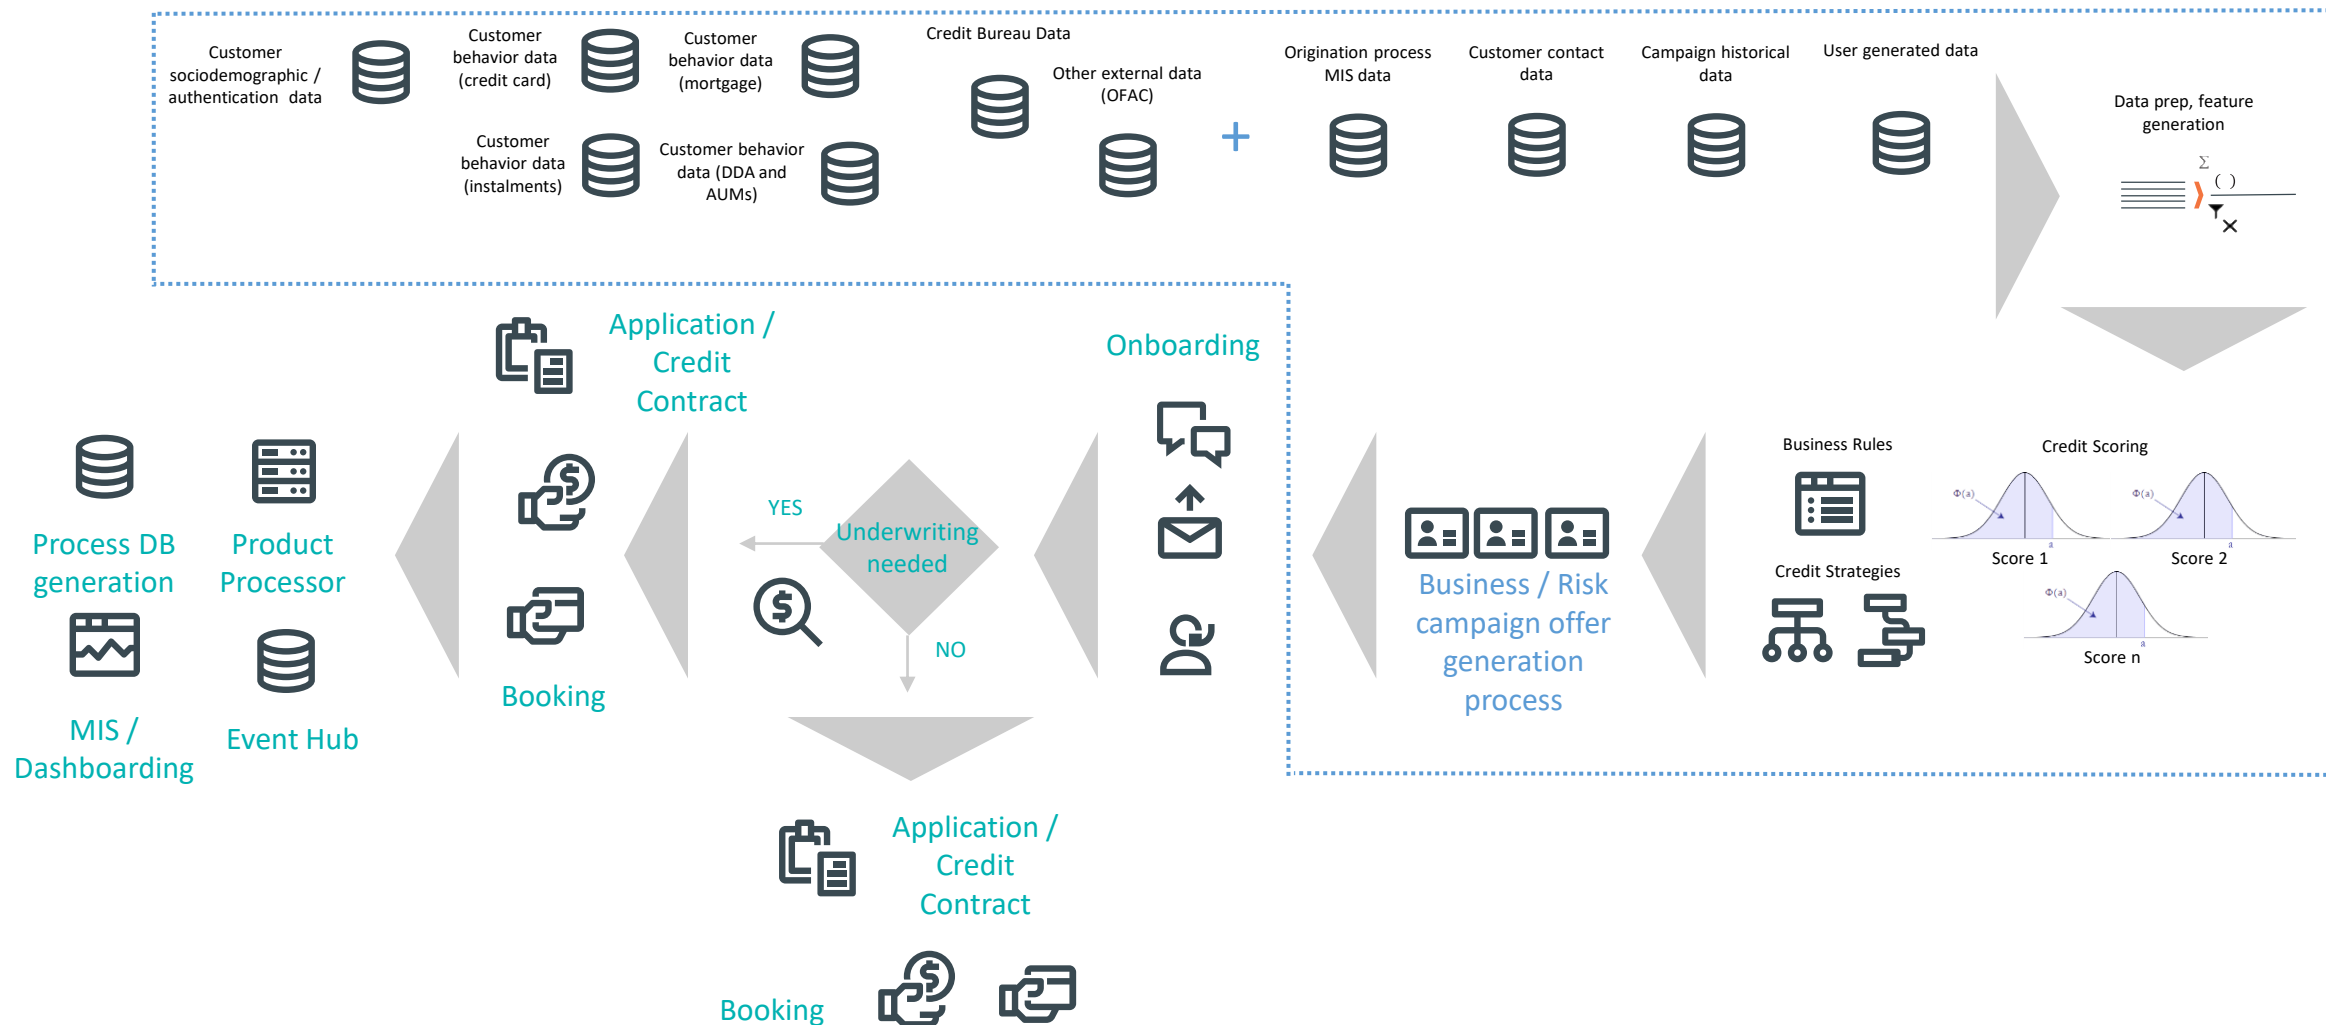


¿Cómo es el Proceso de Evaluación Crediticia en la Corporación X?





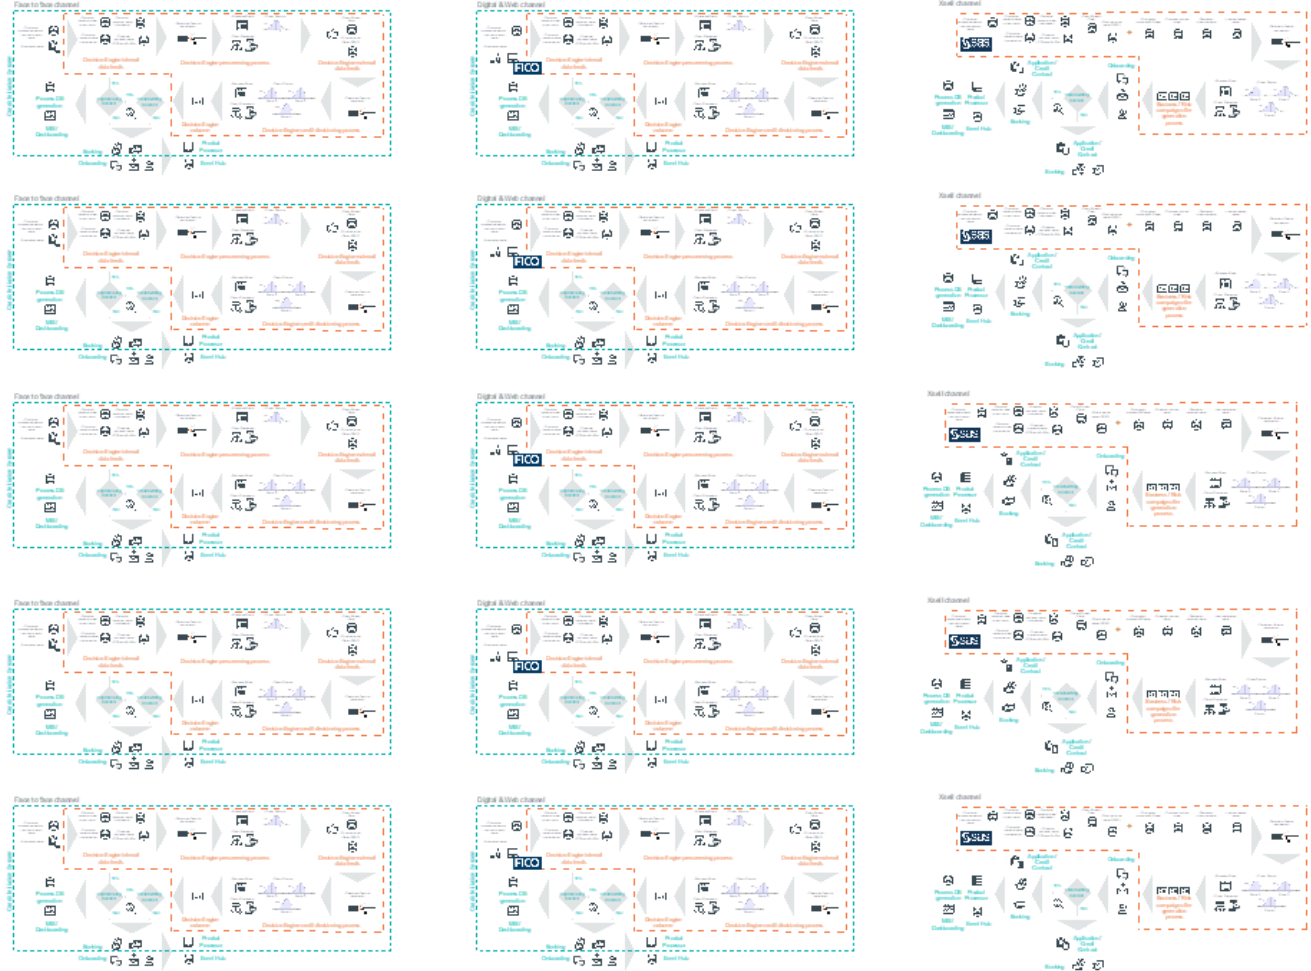
¿Y cómo es el proceso de Gestión de Campañas del Producto N?





Entonces, en la División de Riesgos

- Hay un montón de pipelines, por cada analista y producto.
- Por cada modelo hay tareas de validación por las dependencias correspondientes.
- Y hay pipelines adicionales para los reportes regulatorios.





Lo mismo sucede en otras áreas

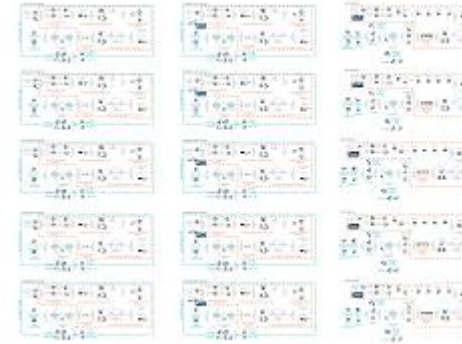
Riesgos



Marketing



Gestión de Clientes



Fraude



Operaciones



Finanzas





Mientras que en el área de Tecnología...

Seguridad

Privacidad

Disponibilidad

Lucha contra
el Fraude

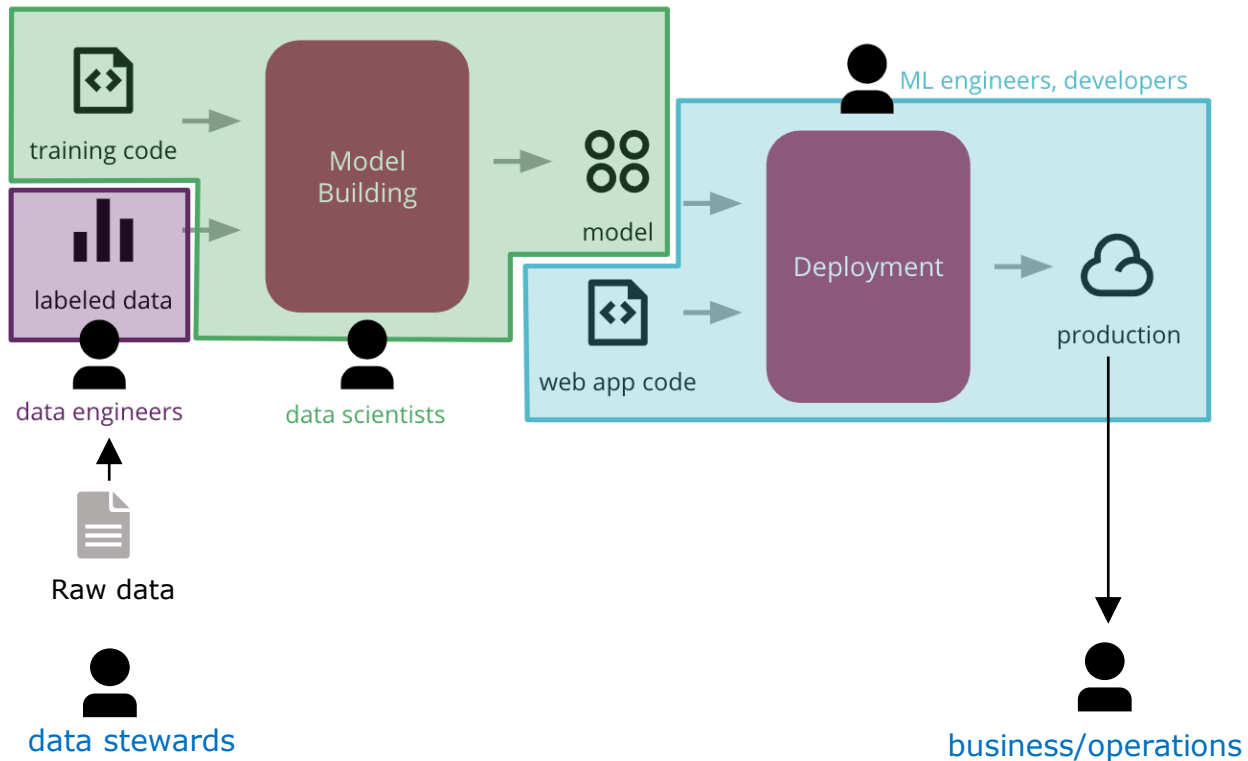
Confiabilidad



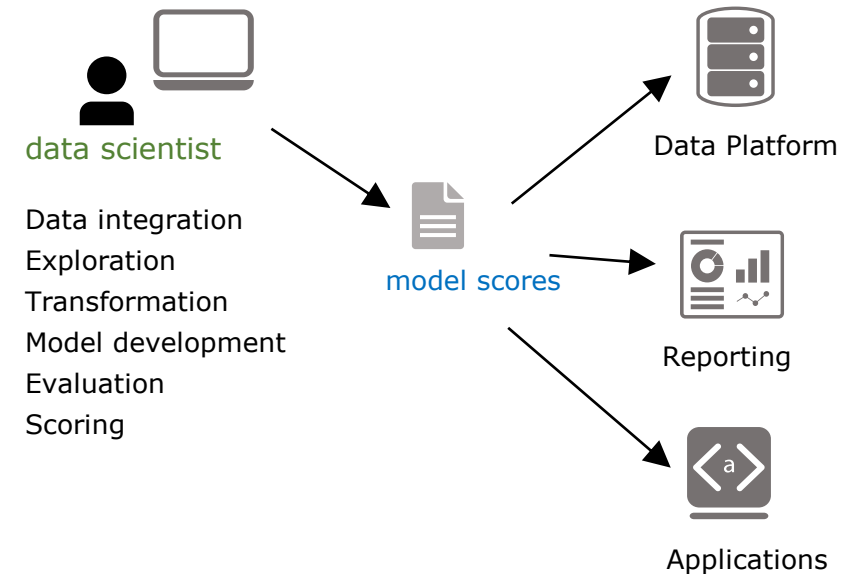


Y en otras Empresas/Organizaciones

Expectativa



Realidad



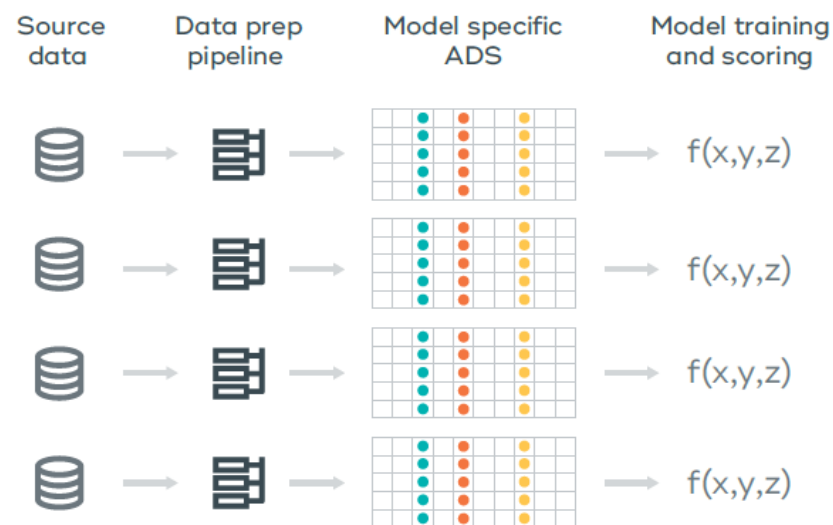
¿Soluciones?

Existen varias alternativas



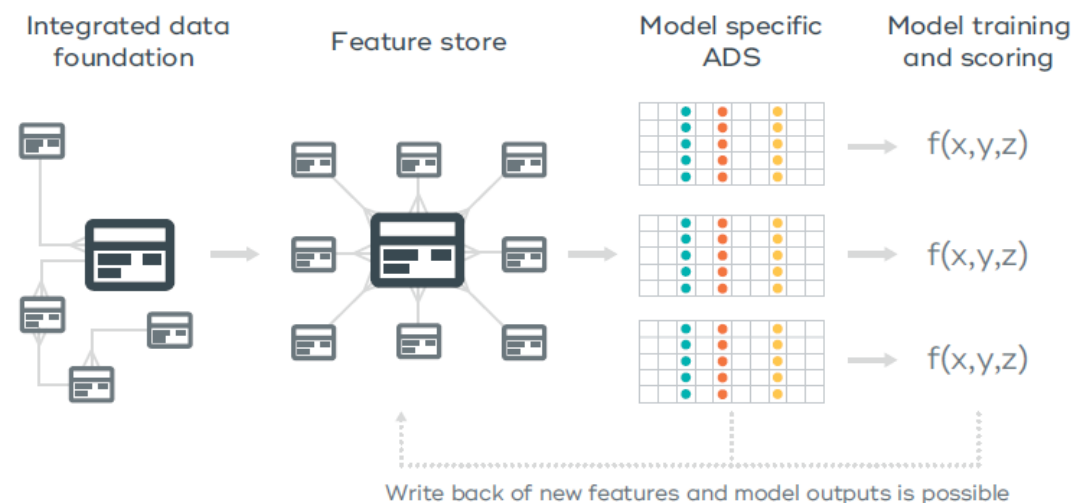
Feature Stores

The one pipeline per model approach



- One pipeline per model
 - Redundant infrastructure, processing and effort
 - Limited re-use of pipeline or features
 - DSs functioning mostly as data janitors
- Long data prep cycles and poor time to market
- High TCO
- Poor productivity and data silos
- Inefficient allocation of resources

The feature store approach



“Off the peg” features dramatically improve analytic cycle time and time-to-market

Extensive re-use reduces TCO and improves analytic data quality and predictive model accuracy

ADS layer enables model-specific customization, whilst eliminating analytic data silos

Separation of duties & improved productivity

Feature
Stores
for ML

OCT 12 AND 13, 2021 | 8:30 AM - 4:00 PM PT

Feature Store Summit

POWERED BY FEATURESTORE.ORG

Discover the latest technologies, best practices, use cases for putting ML models into production environments.

[Request Recordings](#)

[Join Slack](#)

[Agenda](#) [Speakers](#) [Partners](#) [Job Board](#)




MLOps

- Es el proceso de automatizar las tareas de ML **utilizando algunos elementos** de DevOps.
- **IMPORTANTE:** La necesidad de su organización podría ir más allá de sólo automatizar los procesos de ML

Read the full insight:
<https://mck.co/MLOps>

What MLOps delivers

MLOps is a blueprint for combining platforms, tools, services and roles with the right team operating model and standards for delivering AI quickly, reliably and at scale.





Beneficios de MLOps

Antes	Después
Proyectos largos: Implementar sólo un modelo toma muchos meses	Acelerar el time-to-market: Implementación de modelos en menor tiempo
Despliegue manual: Volátil, sujeto a errores, pérdidas y difícil de auditar	Automatización: En el entrenamiento, testeo y pase a producción de modelos
Falta de gobierno: A lo largo de todo el proceso analítico	Incremento de Gobernabilidad: Mayor control y auditabilidad de los procesos
Silos: Tecnología, Analytics y el Negocio trabajando de manera separada	Trabajo colaborativo: Todas las áreas alineadas para optimizar el despliegue
Pobre confiabilidad y escalabilidad: Dificultades para hacer un proceso escalable y robusto	Infraestructura escalable: La solución capaz de evolucionar hacia un nivel aceptable de madurez
Cambios de librerías inmanejables: No se puede dar mantenimiento continuo al entorno productivo por los continuos cambios de versión	Entorno Productivo estable: La infraestructura de scoring se levanta cuando se necesite, y es flexible con las distintas versiones de librerías.

Principales Funcionalidades



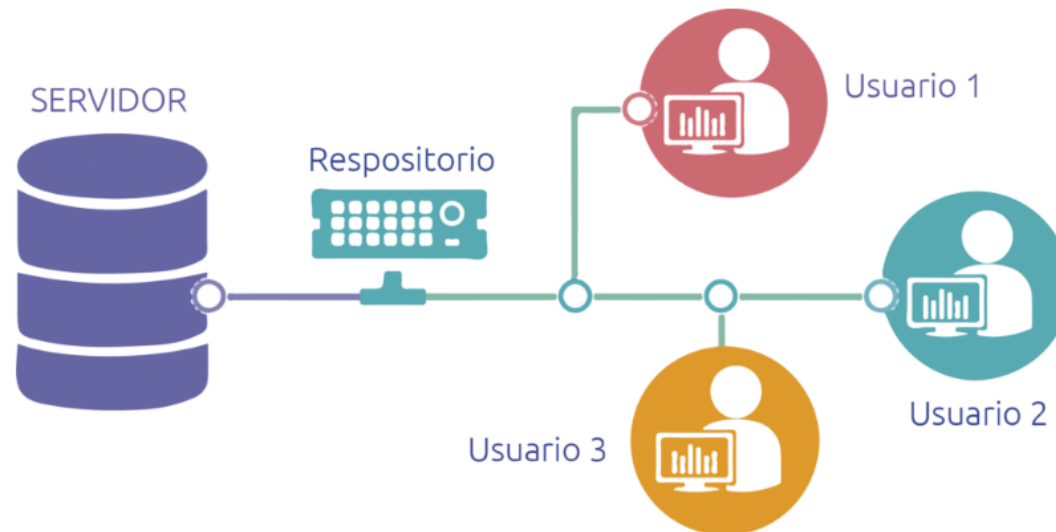
Principales Funcionalidades

- Control de Versiones (Git, Mercurial, VS, SVN, SVC)
- Virtualización (Vagrant, VMWare, VirtualBox)
- Contenedores (Docker)
- Automatización de Flujos de trabajo (Airflow, JBPM)
- Despliegue Automatizado (Jenkins, Bamboo)
- Estándares de Interoperabilidad (PMML, ONNX)



Control de Versiones


- Este es un sistema que te permite realizar seguimiento de la historia de un archivo, además te permite ir de la versión actual a una versión anterior del mismo archivo (Notebooks, scripts).
- Facilita el trabajo colaborativo y la documentación organizada.






Contenedores

- Los contenedores son ambientes livianos que proveen a las aplicaciones con los archivos, variables y librerías que necesitan para operar.
- Se utilizan para garantizar que una aplicación se ejecute correctamente cuando cambie su entorno.



Virtual Machines



Docker Containers

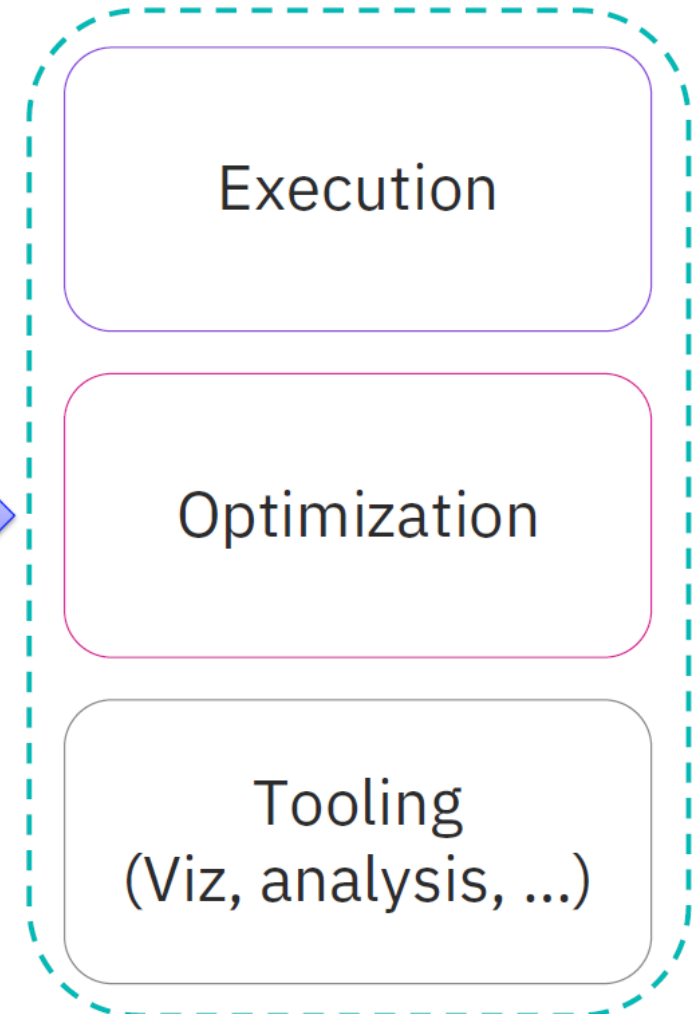


Estándares de Interoperabilidad

Single stack



Standard
Format



PMML



NNVM



ONNX



ONNX

NNEF



Soluciones Disponibles



¿Y qué herramienta es la mejor?



...La que te ayude a cubrir tus necesidades



¿Y qué nube es la mejor?

- ¿Qué vehículo es mejor?



...El que te lleve a donde quieras llegar



Productos en el Mercado

Open Source:

- MLFlow
- KubeFlow
- Seldon
- MetaFlow
- Flyte
- Iguazio
- PredictionIO
- Cnvrg.io



Comerciales:

- SAS
- IBM
- AWS
- Google Cloud
- Azure
- DVC
- Cortex
- Dataiku
- DataRobot
- Domino
- H2O
- Pachyderm
- DatoIn





Principales Funcionalidades

Dependiendo de la solución, podrían comprender las siguientes funcionalidades:

- Conectividad con Feature Stores y Data Pipelines para recibir y entregar resultados directamente al entorno productivo
- Versionado de Datos y Modelos
- Administración de Modelos
- Monitoreo de Modelos
- Tuneo de Parámetros
- Pases a producción automatizados



Principales Funcionalidades

Ambiata (2020) tiene un muy buen artículo comparando funcionalidades de muchas herramientas

	Data and Pipeline Versioning	Model and Experiment Versioning	Hyperparameter Tuning	Model Deployment and Monitoring
Weights & Biases	✓	✓	✓	✓
Kubeflow		✓	✓	✓
MLflow		✓	✓	✓
Polyaxon		✓	✓	✓
Comet		✓	✓	✓
DVC	✓			
Pachyderm	✓			
Neptune		✓		
Replicate		✓		
Optuna			✓	
Ray-Tune			✓	
H2O			✓	✓
DataRobot			✓	✓
Domino				✓
Seldon				✓
Cortex				✓
Hydrosphere				✓

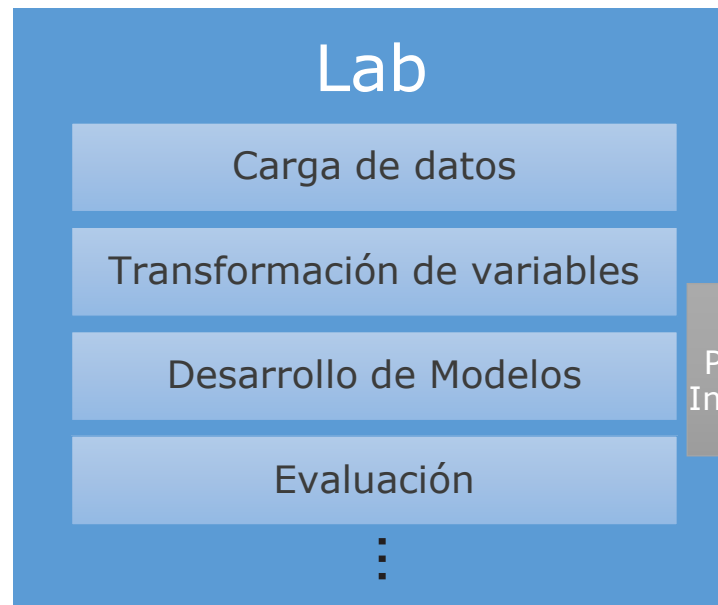
	Sokkit-learn	Conda	Jupyter	R	Java	Sagemaker	Spark	XGBoost	LightGBM	TensorFlow	Keras	PyTorch	MXNet	Caffe	Chainer	Omx
Weights & Biases	✓		✓					✓	✓	✓	✓	✓				
Kubeflow	✓		✓					✓		✓		✓	✓		✓	
MLflow	✓	✓		✓	✓	✓	✓	✓	✓	✓	✓	✓				✓
Polyaxon	✓									✓	✓	✓	✓	✓		
Comet	✓		✓			✓				✓	✓	✓				
DVC	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Pachyderm	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
Neptune			✓	✓		✓			✓	✓	✓	✓				
Replicate	✓							✓		✓		✓				
Optuna	✓							✓	✓	✓	✓	✓	✓		✓	
Ray-Tune	✓							✓		✓	✓	✓				
H2O				✓	✓		✓	✓	✓	✓	✓	✓				
DataRobot							✓	✓		✓		✓				
Domino	✓	✓	✓	✓		✓	✓			✓		✓				
Seldon	✓			✓	✓		✓			✓						
Cortex	✓									✓	✓	✓				✓
Hydrosphere	✓			✓	✓					✓	✓	✓				

Demo *AnalyticOps*




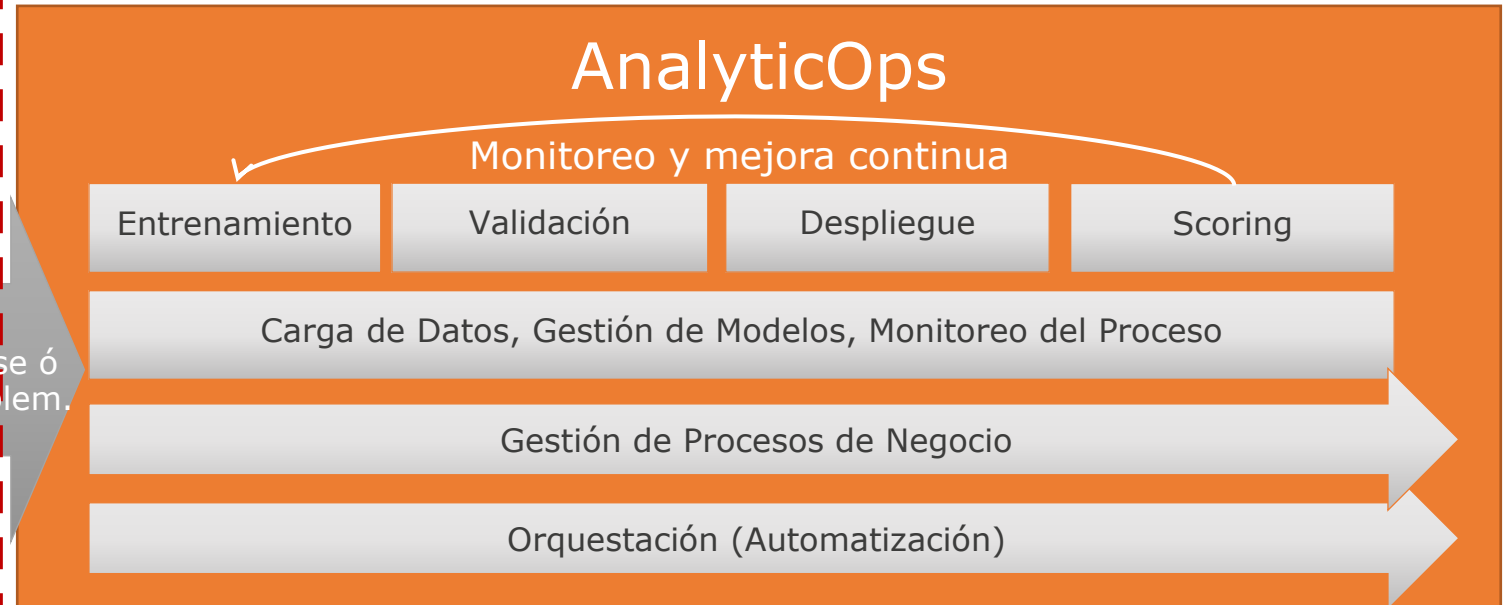
Nuestra Solución en TD: **AnalyticOps**

Discovery/Desarrollo



Pase ó
Implem.

Despliegue/Producción





Ejemplo de Entorno Analítico

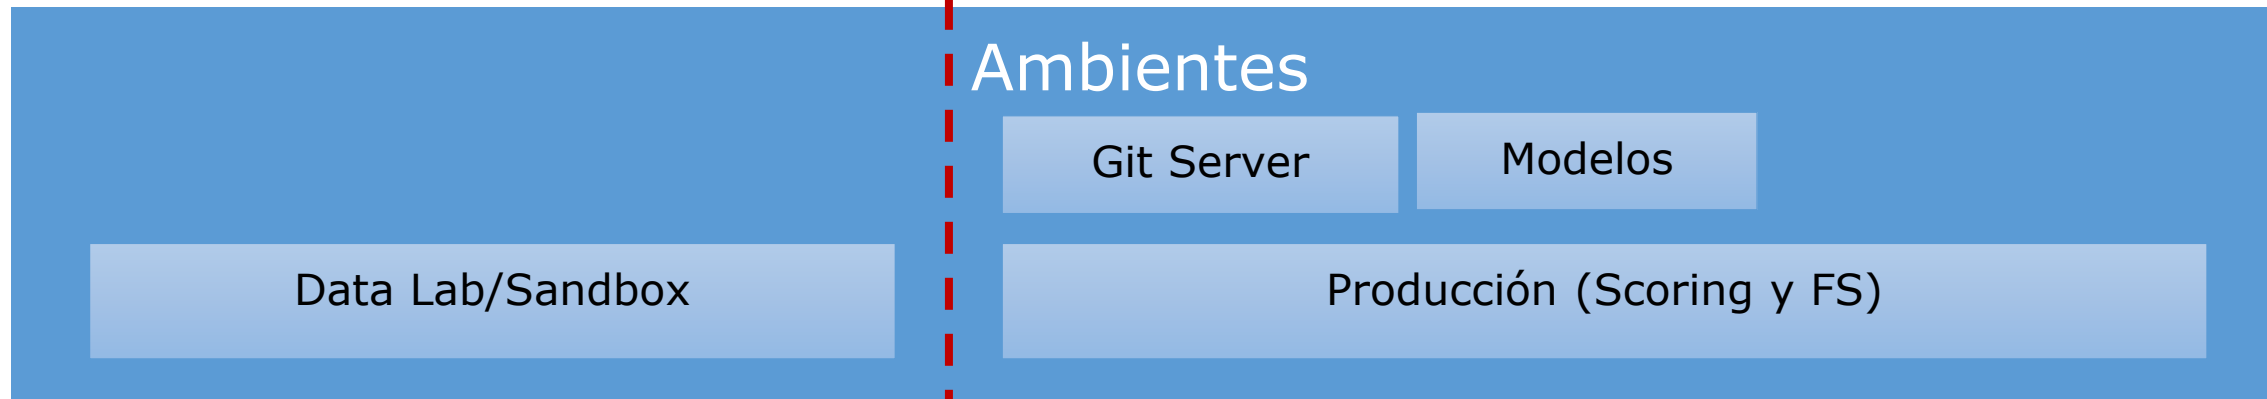
Data Science Lab



AnalyticOps



Ambientes





Beneficios de AnalyticOps

- Entrenamiento automatizado de modelos
- Evaluación, Aprobación y Despliegue de modelos en un clic
- Ejecución periódica batch o en modo API/Real-Time
- Gestión de Modelos
- Integración con LDAP, Kerberos, control de accesos y seguridad
- Diagnóstico y monitoreo continuo de los modelos
- Model Drift
- Champion-Challenger
- Hecho a partir de componentes que ya tiene la organización

Demo *AnalyticOps*



Caso: Default Prediction for Credit Cards

- Este caso tuvo como variable objetivo el incumplimiento de los pagos por los clientes en una entidad financiera de Taiwán. La idea es desarrollar un modelo para estimar la probabilidad de incumplimiento de pago.
- El dataset y el diccionario de datos se encuentran disponibles en la web: <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients#>





Fase 1: Descubrimiento

- **Iteración 1:** Uso de AutoML (PyCaret) para identificar los algoritmos más convenientes.
- **Iteración 2:** Feature Engineering para eliminar la **Multicolinealidad**, originada por tomar varias columnas con correlaciones altas.
- **Iteración 3:** Modelos Ensamblados Básicos (XGBoost, AdaBoost, LightGBM, CatBoost, Decision Trees, KNN, SVM y Regresión Logística).
- **Iteración 4:** Optimización de Parámetros con GridSearch a XGBoost.



Fase 2: Assets

- Códigos de entrenamiento, validación y scoring (.py)
- Datasets de entrenamiento y validación (FS/BD)
- Dataset de scoring implementado automáticamente (FS/BD)
- Listado de Parámetros por cada modelo (.json)
- Librerías requeridas para la ejecución (.txt)

Mensajes finales

(Sí, son varios)



¿De dónde puedo aprender?

- **"The textbook on how to do MLOps has not been written"**
- "El libro que trata sobre cómo hacer MLOps aún no se ha escrito"

Andrew Ng, Marzo 2021
Minuto 39:55

Traditional software vs AI software

Traditional software

Scope project → Develop code → Deploy in production

AI software

Scope project → Collect data → Train model → Deploy in production

Andrew Ng


A Chat with Andrew on MLOps: From Model-centric to Data-centric AI

170.970 visualizaciones • Emitido en directo el 24 mar 2021

5632 23 COMPARTIR GUARDAR ...



¿De dónde puedo aprender?





¿De dónde puedo aprender?



Carlos Gamero • 1er


Director Data & Analytics at Center for Advanced Analytics (Grupo BRECA)

1 semana •

Para que los modelos de Analítica Avanzada generen valor deben de ser puestos en producción, es decir, deben de ser usados regularmente por los usuarios que lo requieran y además, deben articularse con la arquitectura tecnológica de la empresa donde son usados.

Es así, que al constuir una solución de Analítica Avanzada debe de ser diseñada teniendo esto en mente.

Frizzi San Roman y Jose Naranjo del equipo del Centro de Analítica Avanzada de BREIN muestran un ejemplo de como se podría hacer esto. Si deseas saber más, entra a este link:



Modelos en producción

centerforadvancedanalytics.ghost.io • 7 min de lectura

in LEARNING

Explorar

Buscar aptitudes, temas o programas

Inicio

Mi Learning

Notificaciones

Yo

ES

100data

Contenido

Deploying Scalable Machine Learning for Data Science

Scaling ML models

1123

7818

+

142 activos

Deploying Scalable Machine Learning for Data Science

with **Dan Sullivan**

```
},
"RestartPolicy": "Always",
"DNSPolicy": "ClusterFirst",
"NodeSelector": null,
"AutomountServiceAccountToken": null,
"NodeName": "minikube",
"HostNetwork": false,
"HostPID": false,
"HostIPC": false,
"ShareProcessNamespace": null,
"SELinuxOptions": null,
"RunAsUser": null,
"RunAsNonRoot": null,
"SupplementalGroups": null,
"FSGroup": null
},
"ImagePullSecrets": null,
"Hostname": "",
"Subdomain": "",
"Affinity": null,
```

1.5x

Resumen

Preguntas

Libreta

Transcripción

INSTRUCTOR

Dan Sullivan

Enterprise Architect, Big Data Expert

Ver en LinkedIn · Seguir en LinkedIn

RELACIONADO CON ESTE CURSO

Grupos de aprendizaje · [Mostrar todo](#)

Ejercicios · [Mostrar todo](#)

Certificados · [Mostrar todo](#)

Cursos relacionados


CURSO

Machine Learning and AI Foundations: Value Estimations

50.360 usuarios



¿De dónde puedo aprender?



Cada vez que un usuario sube una foto a Mercado Libre, se ejecuta una infinidad de modelos para:

- Detectar texto
- Clasificar el objeto
- Detectar Marca, modelo
- Peso estimado
- Volumen de la caja
- Etc.

Cuando un usuario navega por la web, determinadas acciones también dispara la ejecución de más modelos, como la estimación de costos de envío, tiempo de llegada, etc.

Carlos de la Torre: Del POC a producción - Infraestructura para machine-learning | PyData Córdoba

269 visualizaciones • 16 dic 2019

👍 4 💬 1 ➦ COMPARTIR ≡ GUARDAR ...



¿De dónde puedo aprender?

The role of MLOps on effective AI

Why good MLOps is necessary to carry a successful AI implementation and reduce the deployment gap in any organization.



Carl W Handlin Wallace

Follow

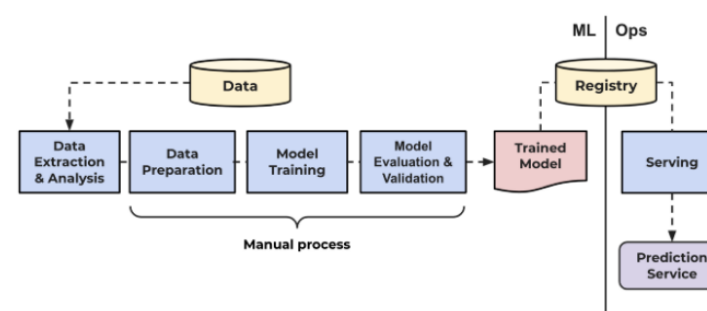


Oct 20 · 6 min read

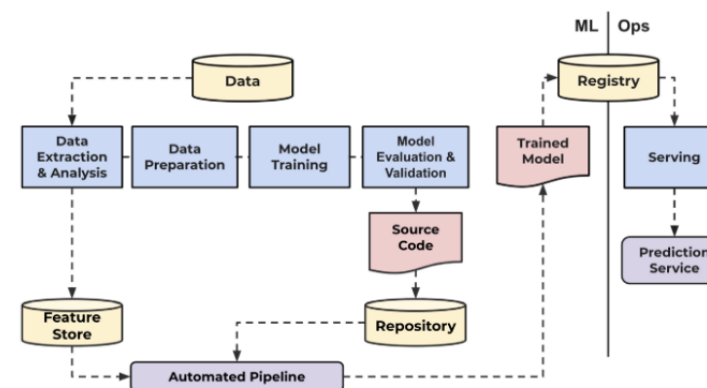


I would like to start this article with some hard facts. On the 2019 MIT Sloan and Boston Consulting Group (BCG) report with the title: “Winning with AI”, 7 out of 10 surveyed companies reported little or no impact with the use of Artificial Intelligence, and around 40% of organizations with **significant investments** in AI reported no benefits or business gains from AI [1]. The reality is that AI is a big source of opportunities and advantages, however, implementing AI is a risk and *implementing it correctly* is hard. There are a lot of reasons and challenges involved into explaining these results across the different organizations: failing to identify business needs and align the AI efforts, lack of organizational agility, cultural resistance, understanding data as an asset, executive leadership, technology solutions, and many more [2].

Level 1: DevOps no MLOps



Level 2: Automated Training





Key Takeaways

1

MLOps es más que DevOps para desarrollar e implementar modelos. Es una nueva forma de gestionar el proceso analítico.

2

Es un buen momento para modernizar procesos, la agilidad para adoptar las innovaciones es clave para la supervivencia.

3

Hay mucho material disponible para aprender, pero es importante enfocarse y seleccionar lo que realmente funciona.



AI · ANALYTICS
SUMMIT

